

BÁO CÁO DỰ ÁN

Dự đoán Khách hàng Rời bỏ Dịch vụ (Customer Churn Prediction)

Môn học: Nhập môn Khoa học Dữ liệu (Intro2DS)

Nguồn dữ liệu: [Kaggle Playground Series S6E3](#)

Nhóm: 14

Năm học: 2025–2026

Thành viên nhóm 14

STT	Họ và tên	MSSV	Vai trò trong dự án	Tỷ lệ đóng góp
1	Nguyễn Lan Anh	24280006	Đóng góp EDA, phát triển frontend cho tính năng dự đoán tỷ lệ rời bỏ và xây dựng CI Pipeline.	14%
2	Lê Văn Đức (Nhóm trưởng)	24280010	Quản lý: Lên kế hoạch, phân công nhiệm vụ, giám sát tiến độ và đánh giá sản phẩm. Kỹ thuật: Backend EDA Dashboard, triển khai web, tổng hợp repo.	15%
3	Trần Quang Huy	24280015	Phân tích Khám phá Dữ liệu (EDA), Kỹ thuật Đặc trưng (Feature Engineering), viết báo cáo và đánh giá dự án.	15%
4	Phạm Tiến Phát	24280018	Đóng góp EDA, phát triển frontend cho tính năng so sánh mô hình.	14%
5	Hoàng Gia Bảo	24280049	Xây dựng pipeline Feature Engineering, phát triển frontend cho tính năng EDA Dashboard.	14%
6	Đặng Hoàng Khang	24280076	Xây dựng pipeline huấn luyện và đánh giá mô hình, phát triển backend cho tính năng so sánh mô hình.	14%
7	Nguyễn Tiến Phát	24280093	Đóng góp EDA, phát triển backend cho tính năng dự đoán tỷ lệ rời bỏ.	14%

Mục lục

1. Tổng quan dự án
 2. Mô tả dữ liệu
 3. Phân tích khám phá dữ liệu (EDA)
 4. Kỹ thuật đặc trưng (Feature Engineering)
 5. Xây dựng Pipeline Machine Learning
 6. Kết quả mô hình
 7. Kết luận và hướng phát triển
-

1. Tổng quan dự án

Đây là Mini Project của nhóm 14, phục vụ cho học phần Nhập môn Khoa học Dữ liệu (Intro2DS). Dự án bao gồm:

- **EDA** để khám phá bộ dữ liệu từ Kaggle: [Kaggle Playground Series S6E3 Data](#)
- **Feature Engineering** để tạo các đặc trưng cho mô hình phân loại.
- **Tạo và huấn luyện** các mô hình phân loại dựa trên kiến trúc MLflow.
- **Trực quan hoá kết quả** và thêm các tính năng tương tác qua web interface.

Các kết quả đạt được:

- **GitHub Repository:** [customer_churn_prediction](#)
- **File báo cáo kết quả:** [report.pdf](#)
- **Web interface:** [Vercel Web App](#)

1.1. Bối cảnh

Đối với lĩnh vực viễn thông và dịch vụ số nói chung, việc giữ chân khách hàng có ý nghĩa chiến lược quan trọng, khi chi phí bỏ ra để thu hút khách hàng mới thường cao gấp nhiều lần so với chi phí giữ chân khách hàng hiện tại. Dự án **Customer Churn Prediction** xây dựng một hệ thống học máy **Machine Learning** nhằm dự báo khả năng khách hàng rời bỏ dịch vụ nhằm hỗ trợ doanh nghiệp kịp thời khi xuất hiện rủi ro rời bỏ dịch vụ.

1.2. Mục tiêu

- **Phân tích khám phá dữ liệu (EDA):** Khảo sát chất lượng dữ liệu, phân phối các đặc trưng và động cơ rời bỏ của khách hàng — thông qua các khảo sát sơ bộ để đưa ra các quyết định cụ thể về encoding, sampling.
- **Kỹ thuật đặc trưng:** Biến đổi dữ liệu thô thành không gian vector tinh gọn, giảm đa cộng tuyến và tăng mật độ thông tin cho các mô hình.
- **Xây dựng pipeline MLOps:** Triển khai quy trình tự động hóa 6 giai đoạn từ thu thập dữ liệu đến dự đoán, đảm bảo khả năng vận hành end-to-end hoặc từng stage riêng lẻ.

- **Huấn luyện và đánh giá mô hình:** So sánh LightGBM và XGBoost qua GridSearchCV, chọn mô hình tốt nhất dựa trên ROC AUC và theo dõi bằng MLflow.

1.3. Phạm vi dự án

Hạng mục	Chi tiết
Tập huấn luyện	594.194 mẫu, 21 cột
Tập kiểm tra (Kaggle)	254.655 mẫu
Số đặc trưng sau xử lý	23 features
Thuật toán	LightGBM, XGBoost
Metric chính	ROC AUC, F1-Score

1.4. Phương pháp tiếp cận

Dự án được triển khai theo luồng **EDA → Feature Engineering → Pipeline → Modeling**, trong đó mỗi insight từ EDA đều dẫn đến những quyết định kỹ thuật cụ thể:

Giai đoạn	Vấn đề cần giải quyết	Kết quả đầu ra
Data Quality	Tính nhất quán và toàn vẹn dữ liệu	Quy tắc lọc dòng, loại bỏ biến nhiễu
Univariate	Quan sát, đánh giá phân phối và sự mất cân bằng biến mục tiêu	Stratified split, SMOTE
Bivariate	Khảo sát ảnh hưởng các đặc trưng lên biến mục tiêu	Các đặc trưng Kỹ thuật hóa
Correlation	Khảo sát mức độ ảnh hưởng và rà soát đa cộng tuyến giữa các đặc trưng	Tinh gọn không gian vector
Pipeline	Tái lập quy trình huấn luyện và đánh giá mô hình	Các stage tự động, artifact chuẩn hóa
Modeling	Đánh giá hiệu năng của các mô hình	Mô hình tốt nhất, được ưu tiên sử dụng cho quá trình mô phỏng sau này

2. Mô tả dữ liệu

2.1. Nguồn dữ liệu

Dữ liệu được lấy từ cuộc thi **Kaggle Playground Series Season 6 Episode 3**, mô phỏng bài toán dự đoán churn của một nhà cung cấp dịch vụ viễn thông/Internet.

2.2. Cấu trúc đặc trưng

Dữ liệu gồm **21 cột**, được phân loại như sau:

Nhóm	Số lượng	Ví dụ
Định danh	1	id
Định lượng	3	tenure , MonthlyCharges , TotalCharges
Định tính	16	Contract , InternetService , PaymentMethod , ...
Mục tiêu	1	Churn (Yes/No)

Các đặc trưng gốc:

Cột	Kiểu dữ liệu	Mô tả
id	int64	Mã định danh của khách hàng
gender	object	Giới tính
SeniorCitizen	int64	Khách hàng có là người cao tuổi ≥ 65 tuổi ? (1: Có, 0: Không)
Partner	object	Khách hàng có sống chung với vợ/chồng?
Dependents	object	Khách hàng có cần được chăm sóc?
tenure	int64	Thời gian sử dụng dịch vụ : Thời gian khách hàng đã gắn bó và sử dụng dịch vụ, tính theo tháng
PhoneService	object	Khách hàng có đăng ký dịch vụ điện thoại?
MultipleLines	object	Khách hàng có sử dụng nhiều đường dây điện thoại cùng lúc?
InternetService	object	Loại dịch vụ Internet mà khách hàng đang dùng
OnlineSecurity	object	Khách hàng có đăng ký gói bảo mật mạng trực tuyến?
OnlineBackup	object	Khách hàng có đăng ký gói sao lưu dữ liệu đám mây?
DeviceProtection	object	Khách hàng có mua gói bảo vệ thiết bị?
TechSupport	object	Khách hàng có đăng ký dịch vụ hỗ trợ kỹ thuật?
StreamingTV	object	Khách hàng có sử dụng Internet để xem truyền hình?
StreamingMovies	object	Khách hàng có sử dụng Internet để xem phim trực tuyến?

Cột	Kiểu dữ liệu	Mô tả
Contract	object	Loại hợp đồng thanh toán khách hàng đã ký?
PaperlessBilling	object	Khách hàng có nhận hóa đơn điện tử?
PaymentMethod	object	Phương thức thanh toán
MonthlyCharges	float64	Cước phí theo tháng, ghi nhận vào tháng cuối cùng khảo sát được
TotalCharges	float64	Tổng cước phí, ghi nhận trong suốt quá trình khảo sát
Churn	object	Biến mục tiêu (Target) : Đến thời điểm kết thúc khảo sát, khách hàng có rời bỏ dịch vụ không?

2.3. Tiền xử lý dữ liệu

Quá trình làm sạch dữ liệu trong notebook EDA và pipeline tuân theo nguyên tắc bảo đảm tính toàn vẹn dữ liệu:

1. **Chuyển đổi kiểu dữ liệu:** `TotalCharges` được ép sang kiểu số thực vì file gốc có thể chứa khoảng trắng hoặc giá trị không hợp lệ.
2. **Chuẩn hóa nhãn:** `SeniorCitizen` chuyển từ 0/1 sang Yes/No để đồng nhất với các biến nhị phân khác trong quá trình phân tích; khi huấn luyện mô hình sẽ map lại về 0/1.
3. **Kiểm tra logic nghiệp vụ:** Không phát hiện mâu thuẫn giữa `InternetService = No` và các dịch vụ phụ thuộc Internet hiển thị Yes — dữ liệu nhất quán về mặt nghiệp vụ.
4. **Xử lý dữ liệu lỗi:** Loại bỏ các khách hàng mà **không dùng cả Internet lẫn điện thoại** `InternetService = No AND PhoneService = No`, vì sự thiếu trực quan trong khả năng phản ánh hành vi tiêu dùng của khách hàng.

2.4. Ý nghĩa nghiệp vụ

Mỗi bản ghi tương ứng với một hồ sơ khách hàng đăng kí sử dụng dịch vụ viễn thông, với các thông tin cơ bản về:

- **Cam kết hợp đồng** (`Contract`): ràng buộc pháp lý và thời hạn gắn bó.
- **Hạ tầng dịch vụ** (`InternetService`, `PhoneService`, các gói bổ trợ): các dịch vụ được sử dụng tương ứng.
- **Hành vi thanh toán** (`PaymentMethod`, `PaperlessBilling`): phương thức và hình thức thanh toán.
- **Bối cảnh cá nhân** (`SeniorCitizen`, `Partner`, `Dependents`): hồ sơ nhân khẩu học của khách hàng bao gồm độ tuổi, tình trạng hôn nhân và tình hình phụ thuộc tài chính.
- **Chi phí** (`MonthlyCharges`, `TotalCharges`, `tenure`): áp lực tài chính của khách hàng, được thể hiện thông qua các mức phí theo tháng, tổng cước phí và thời gian sử dụng

dịch vụ.

Biến mục tiêu `Churn` trả lời câu hỏi *Khách hàng này có rời bỏ dịch vụ trong kỳ quan sát không?*

3. Phân tích khám phá dữ liệu (EDA)

Các insight từ bước này sẽ cho ta góc nhìn trực quan để đưa ra các quyết định kỹ thuật ở các bước sau, có thể kể đến như chiến lược mã hóa, metric đánh giá, feature selection và feature engineering. Các bước encoding, SMOTE và stratified sampling sẽ không được thực hiện trong notebook EDA mà sẽ được quản lý tập trung trong pipeline.


3.1. Kiểm định chất lượng dữ liệu (Data Quality Assessment)

3.1.1. Biến định lượng

Note: Mục tiêu là kiểm chứng tính hợp lệ toán học và logic nghiệp vụ — `tenure` phải là số nguyên dương, `MonthlyCharges` và `TotalCharges` không âm.

Các trường hợp kiểm tra logic nghiệp vụ	Số lỗi phát hiện tương ứng
Số tháng sử dụng dịch vụ không nguyên dương	0
Giá cước hàng tháng không dương	0
Tổng cước không dương	0

Nhận xét: Kết quả đồng loạt bằng **0** lỗi logic chứng minh các biến định lượng hoàn toàn hợp lệ. Vì vậy, **không** ép kiểu, xóa dòng lỗi hay imputation trước khi phân tích. Quá trình Feature Engineering sau đó cũng được thiết kế để tránh `ZeroDivisionError` và giá trị `Inf`.



Qua Boxplot và kiểm định chéo: `tenure`, `MonthlyCharges`, `TotalCharges` **không có outlier bất thường** — các thao tác imputation, dropping hay capping được **lược bỏ hoàn toàn**.


3.1.2. Biến định tính

Note: Rà soát nhất quán nhãn và logic phân lớp giữa dịch vụ cốt lõi và dịch vụ bổ trợ.

Các trường hợp kiểm tra logic nghiệp vụ	Số lỗi phát hiện tương ứng
Sử dụng dịch vụ Internet nhưng không có Internet	0
Sử dụng Internet nhưng không có dịch vụ Internet	0
Sử dụng dịch vụ điện thoại nhưng không có điện thoại	0
Sử dụng điện thoại nhưng không có dịch vụ điện thoại	0
Không đăng ký bất kỳ dịch vụ nào	7

Phát hiện **7 khách hàng** có `PhoneService = No` **đồng thời** `InternetService = No` — hợp đồng không sử dụng bất kỳ hạ tầng kết nối cơ bản nào, là lỗi logic trong quá trình nhập liệu. Sau khi loại bỏ hoàn toàn 7 quan sát này (594.194 → **594.187** dòng), tập dữ liệu đã được đồng bộ logic tuyệt đối. Sự trùng khớp giữa nhóm *No internet service / No phone service* với trạng thái dịch vụ tạo điều kiện thuận lợi cho One-Hot Encoding, tránh các nhiễu nội tại khi phân tích chuyên sâu hơn.

3.2. Phân tích đơn biến — Biến định lượng



Nhận xét về phân phối:

- tenure**: Phân phối **hai đỉnh (Bimodal)** — khách hàng tập trung phần lớn ở nhóm bắt đầu tiếp xúc với dịch vụ (< 6 tháng) và nhóm khách hàng gắn bó lâu dài (≥ 60 tháng); giữa hai đỉnh phân bố tương đối đồng đều.
- MonthlyCharges**: Mật độ khách hàng rất cao ở mức phí thấp; phần còn lại trải từ **40\$** đến **115\$** với các đỉnh nhỏ, không có mức cước áp đảo.
- TotalCharges**: **Lệch phải mạnh** — đa số tập trung **0–2.000\$**, đuôi kéo đến hơn **8.000\$**, phân bố này khá hợp lý khi nhóm khách hàng mới và nhóm khách hàng sử dụng gói cơ bản chiếm tỷ trọng lớn.


Kết luận:

- tenure** nên được chia theo thời gian gắn bó (khách mới 1–6 tháng / tiêu chuẩn 7–48 tháng / lâu năm > 48 tháng) — ưu tiên **Ordinal Encoding** để giữ tính thứ bậc của biến

này.

- `MonthlyCharges` và `TotalCharges` chênh lệch biên độ lớn → cần chuẩn hóa (**StandardScaler / Min-Max**) khi áp dụng các mô hình nhạy với khoảng cách.
- `TotalCharges` lệch phải nhưng không có outlier bất thường trên Boxplot — thực hiện kiểm tra tính đa cộng tuyến với các đặc trưng định lượng khác, loại bỏ nếu cần thiết.

3.3. Phân tích đơn biến — Biến định tính



Nhận xét:


- Đa số đặc trưng mang **2–3** nhãn; `PaymentMethod` mang nhiều nhãn nhất cũng có độ phân hóa thấp với chỉ **4** giá trị.
- Không xuất hiện **Rare Labels** — nhóm nhỏ nhất chiếm **6,1%** (`No phone service` trong `PhoneService` và `MultipleLines`).
- `PhoneService` : `Yes` chiếm **93,89%**, mất cân bằng lớn, tính phân hóa thấp, khả năng gây nhiễu cao.
- Các dịch vụ Internet có nhóm `No internet service` cố định **23,7%**; `MultipleLines` có `No phone service` **6,1%**. Ta **không gộp** các nhãn này với `No`, vì đây là các nhóm quan trọng,

mang lại nhiều thông tin trong quá trình phân tích.

Kết luận:

- Có thể áp dụng **One-Hot Encoding** đồng loạt vì số nhãn thấp, không tiềm ẩn rủi ro bùng nổ chiều dữ liệu.
- `PhoneService` mang tính nhiễu, kỳ vọng đóng góp dự báo ở mức thấp.

3.4. Phân tích đơn biến — Biến mục tiêu `Churn`




Nhận xét: Dữ liệu mất cân bằng ở mức vừa phải, tỷ lệ **3,5 : 1** — *Tiếp tục sử dụng 77,5%, Rời bỏ 22,5%.*

Định hướng:

- Thực hiện **Stratified Sampling** khi chia tập huấn luyện — giữ tỷ lệ **22,5%** churn trên mọi fold.
- Sử dụng các metric **F1-Score**, **Precision-Recall AUC** và **ROC-AUC** thay vì Accuracy.
- Cân bằng lớp: **SMOTE** trên tập huấn luyện; có thể dùng `scale_pos_weight` với XGBoost.

3.5. Phân tích song biến — Biến định lượng vs `Churn`

Note: Trực quan hóa bằng Histplot/KDE và Boxplot để phát hiện điểm gãy phân phối và ngưỡng giá trị.




Nhận xét:

- **tenure** : Nhóm *Rời bỏ dịch vụ* tập trung ở khoảng **1–6 tháng** đầu; nhóm *Tiếp tục sử dụng dịch vụ* chiếm ưu thế khi thời gian sử dụng dịch vụ trên **48 tháng**. Trung vị tenure nhóm rời đi khá thấp với khoảng **10 tháng**.
- **MonthlyCharges** : Nhóm *Tiếp tục sử dụng dịch vụ* có mật độ cao ở **~20\$**; nhóm *Rời bỏ* tập trung phân khúc cao **70\$–105\$**. Trung vị cước nhóm rời đi cao hơn hẳn so với nhóm tiếp tục sử dụng dịch vụ, cho thấy **nhóm khách hàng sử dụng dịch vụ với chi phí cao** có xu hướng **rời bỏ dịch vụ**.
- **TotalCharges** : Cả hai nhóm đều có phân phối lệch phải; tuy nhiên nhóm rời đi tập trung chiếm phần **áp đảo** ở mốc **~0\$**, điều này khá hợp lý khi họ hủy hợp đồng sớm, tổng chi phí tích lũy chưa cao.

3.6. Phân tích song biến — Risk Spread (biến định tính)

Note: Đánh giá **Risk Spread** giữa nhãn rủi ro cao nhất và thấp nhất trong cùng một đặc trưng.



Nhận xét — các đặc trưng phân hóa mạnh:

Đặc trưng	Risk Spread	Chi tiết
PaymentMethod	41,97%	Electronic check 48,91% vs Credit card automatic 6,93%
Contract	41,06%	Month-to-month 42,05% vs Two year 1,00%
InternetService	40,11%	Fiber optic 41,54% vs No internet 1,4%
OnlineSecurity , TechSupport	> 40%	Không đăng ký → churn > 40%; có dịch vụ → < 10%
SeniorCitizen	31,05%	Yes 50,03% (quy mô nhỏ 11,41%)

Nhóm nhiều (Risk Spread < 10%): gender chỉ 0,57%; PhoneService , MultipleLines có mức phân hóa rất thấp.

3.7. Tỷ lệ rời bỏ dự kiến — Toxic traits

Note: Chuyển tiếp từ quan sát Risk Spread sang Churn Rate theo phân khúc để nhận diện đặc điểm hành vi độc hại (Toxic traits).

Đặc trưng	Ý nghĩa đặc trưng	Giá trị mang rủi ro cao nhất	Quy mô tệp KH rủi ro	Tỷ lệ rời bỏ nhóm rủi ro	Tỷ lệ rời bỏ dự kiến
PhoneService	Dịch vụ điện thoại	Yes	93.89%	22.89%	21.49%

Đặc trưng	Ý nghĩa đặc trưng	Giá trị mang rủi ro cao nhất	Quy mô tệp KH rủi ro	Tỷ lệ rời bỏ nhóm rủi ro	Tỷ lệ rời bỏ dự kiến
Contract	Loại hợp đồng	Month-to-month	50.31%	42.05%	21.16%
Dependents	Tiêu chí người chăm sóc	No	69.74%	29.14%	20.32%
OnlineSecurity	Dịch vụ bảo mật trực tuyến	No	48.72%	40.61%	19.79%
PaperlessBilling	Dịch vụ hóa đơn điện tử	Yes	61.53%	31.94%	19.65%
TechSupport	Dịch vụ hỗ trợ kỹ thuật	No	48.57%	40.16%	19.50%
InternetService	Loại dịch vụ Internet	Fiber optic	45.84%	41.54%	19.04%
PaymentMethod	Phương thức thanh toán	Electronic check	36.25%	48.91%	17.73%
SeniorCitizen	Tiêu chí người cao tuổi	No	88.59%	18.98%	16.81%
OnlineBackup	Dịch vụ sao lưu trực tuyến	No	42.09%	39.10%	16.46%

Nhận xét:


- SeniorCitizen = Yes có tỷ lệ rời bỏ dịch vụ đạt **50%** nhưng quy mô chỉ **11,41%** nên không lọt top *tỷ lệ rời bỏ dự kiến*.
- PhoneService = Yes có tỷ lệ rời bỏ dịch vụ dự kiến là **21,49%** và Dependents = No đạt **20,32%**, phần lớn là do quy mô tệp lớn (**93,89%** và **69,74%**), phản ánh tỷ lệ rời bỏ dịch vụ tự nhiên của hệ sinh thái.

Phân khúc ảnh hưởng lớn nhất với quy mô lớn và tỷ lệ rời bỏ ở mức báo động:

1. Contract = Month-to-month — **21,16%**, cứ **5** khách hàng sẽ có **1** người rời đi
2. InternetService = Fiber optic — **19,04%**
3. PaymentMethod = Electronic check — **17,73%**

3.8. Risk Gap — Sức giữ chân hệ sinh thái dịch vụ

Note: Khi tính sức giữ chân, ta loại trừ nhóm khách hàng không sử dụng Internet và điện thoại để tính sự chênh lệch tỷ lệ rời bỏ dịch vụ giữa nhóm *có* và *không* sử dụng dịch vụ hỗ trợ.



Nhận xét:

- **Security & Support** có sức giữ chân hiệu quả nhất khi `OnlineSecurity` và `TechSupport` kéo tỷ lệ rời bỏ dịch vụ từ ~40% xuống 8,7% và 9,6% (chênh lệch > 30%).
`OnlineBackup`, `DeviceProtection` cũng thể hiện sự hấp dẫn với mức giữ chân 20%.
- **Streaming** trái với kỳ vọng ban đầu khi mức chênh lệch chỉ đạt 1,3%–1,6%, cho thấy dịch vụ này có xu hướng dễ bị thay thế bởi nền tảng bên thứ ba, chưa tạo được sự gắn kết với khách hàng.

→ Phân tích này là cơ sở để gom 4 dịch vụ bảo vệ vào hệ thống đặc trưng `security_score`, 2 dịch vụ streaming vào nhóm `streaming_score`.

3.9. Tổng kết EDA

- **Yếu tố rủi ro đỉnh:** hợp đồng ngắn, Fiber optic, thanh toán thủ công, thiếu bảo mật/hỗ trợ.
- **Yếu tố giữ chân:** hợp đồng dài hạn, Security/Support, thanh toán tự động, gia đình (rào cản chuyển đổi).
- **Biến loại bỏ sớm:** `gender`, `TotalCharges`.
- **Metric & sampling:** Ưu tiên sử dụng stratified split, ROC-AUC/F1, SMOTE.

4. Kỹ thuật đặc trưng (Feature Engineering)

Note: Feature Engineering cô đọng mật độ thông tin rủi ro, tối ưu không gian biểu diễn để **LightGBM** và **XGBoost** rẽ nhánh hiệu quả.


Tại sao phân tích tương quan lại thuộc Feature Engineering?

Trong quy trình xây dựng mô hình học máy, phân tích tương quan đóng vai trò nền tảng của giai đoạn **Lựa chọn đặc trưng (Feature Selection)** và **Xử lý đa cộng tuyến (Multicollinearity)**, vốn là một phần không thể tách rời của Feature Engineering: 1. **Loại bỏ đặc trưng dư thừa (Đa cộng tuyến):** Việc phát hiện các cặp biến có tương quan cực kỳ cao (như `TotalCharges` tương quan mạnh với `tenure` với hệ số $r = 0.77$) cho thấy chúng mang thông tin trùng lặp. Việc giữ cả hai sẽ làm nhiễu mô hình, làm phân tán trọng số phân nhánh của các cây quyết định. 2. **Đánh giá mức độ đóng góp (Feature Selection):** Phân tích tương quan (như hệ số Pearson, Spearman cho biến số và hệ số Cramer's V cho biến phân loại) giúp định lượng trực tiếp mối quan hệ tuyến tính/phi tuyến giữa các đặc trưng với biến mục tiêu `Churn`. Nhờ đó, ta có thể thiết lập bảng xếp hạng độ ưu tiên để giữ lại những đặc trưng chất lượng nhất (nguyên tắc Winner-takes-all) và loại bỏ các biến nhiễu hoặc không đóng góp thông tin (như `gender`, `bill_shock_ratio`).

4.1. Rời rạc hóa phi tuyến — `loyalty_tier` và `charge_segment`

Feature	Bins	Nhãn
<code>loyalty_tier</code>	[0, 6, 12, 24, 48, ∞]	Onboarding → First Year → Second Year → Familiar → Loyal
<code>charge_segment</code>	[0, 35, 70, ∞]	Budget → Standard → Premium

Interaction Validation (Heatmap):



Nhận xét — Compounding Risk Effect:

- *Onboarding + Premium*: có tỷ lệ rời bỏ đáng báo động **77,4%**, cho thấy áp lực chi phí cao khi mới sử dụng dịch vụ là rủi ro lớn khiến khách hàng rời bỏ dịch vụ.
- Rủi ro rời bỏ dịch vụ của nhóm *Premium* giảm dần, từ **77,4%** đến **48,1%** và cuối cùng là **8,2%** khi thời gian gắn bó tăng, cho thấy phần lớn áp lực đến từ việc tiếp xúc với gói cước đắt đỏ khi chưa trải nghiệm hoàn toàn giá trị dịch vụ.
- Nhóm *Budget* có tỷ lệ rời bỏ giảm dần từ **16,5%** đến mức **0,4%** ở nhóm trung thành, cho thấy sự gắn bó tự nhiên xuất phát từ gói cước phù hợp với khả năng chi trả.

Kết luận: Phân hóa rủi ro trên Heatmap chứng minh mật độ **Information Density** của hai đặc trưng mới này ở mức cao; `loyalty_tier` và `charge_segment` mang tính bổ trợ cho nhau rất tốt, không bị trùng lặp thông tin đầu vào.

4.2. Chỉ số tài chính phái sinh




Feature	Công thức	Kết quả
<code>charge_to_tenure_ratio_log</code>	<code>log1p(MonthlyCharges / tenure)</code>	KDE phân tách một cách hoàn hảo, cho thấy khách hàng bị áp lực về giá so với thời gian sử dụng dịch vụ có xu hướng rời bỏ dịch vụ hơn nhóm gắn bó lâu dài hay nhóm có mức phí thấp
<code>average_cost_per_service</code>	<code>MonthlyCharges / total_active_services</code>	Khách hàng có xu hướng rời bỏ dịch vụ do số tiền bỏ ra cho mỗi dịch vụ cao hơn mức thông thường hơn là do cước tháng cao
<code>bill_shock_ratio</code>	<code>MonthlyCharges / (TotalCharges/tenure)</code>	Trực quan hóa cho thấy phân phối của hai nhóm rời bỏ và gắn bó không có sự khác biệt rõ rệt khi đồ thị của hai nhóm gần như chồng khít lên nhau. Đây không phải là đặc trưng dự báo rủi ro tốt và cần được loại bỏ khỏi mô hình

Kết luận: Giữ `charge_to_tenure_ratio_log`, `average_cost_per_service`; loại `bill_shock_ratio` (không **Information Gain**).


4.3. Hệ thống điểm số hệ sinh thái

Note: Ta thực hiện gán điểm **-1** cho nhóm khách hàng không đăng kí dịch vụ cơ bản, tức `InternetService = No` hoặc `PhoneService = No` để loại bỏ **Confounding Bias**.




Feature	Thang	Nhận xét
<code>security_score</code>	-1 → 4	Nhóm 0 điểm có tỷ lệ rời bỏ dịch vụ lên đến 52,7% , phân hóa rất mạnh so với nhóm đăng kí đủ 4 dịch vụ với tỷ lệ rời bỏ chỉ 1,4%
<code>streaming_score</code>	-1 → 2	Nhóm 1 điểm có tỷ lệ rời bỏ dịch vụ lên đến 32,8% , kể cả khi đăng kí cả 2 dịch vụ hay không đăng kí dịch vụ nào, mức này vẫn không có sự chênh lệch rõ rệt với mức tương ứng là 27,2% và 28,9%

4.4. Cờ rủi ro hành vi (Churn triggers)



Đặc trưng	Rủi ro rời bỏ dịch vụ
zero_supportive_service	52,7%
manual_payment	34,0% vs 7,3%
composite_risk_profile	55,0%


4.5. demographic_profile — Domain-Driven Interaction



Persona	Rủi ro rời bỏ dịch vụ	Quy mô
Nuclear Family	10,6%	48,8%
Isolated Senior	60,3%	5,9%
Supported Senior	39,1%	3,5%

Nhận xét: Có sự dịch chuyển của rủi ro dời bỏ dịch vụ và quy mô theo chiều hướng đối nghịch, nhóm có tỷ lệ rời bỏ dịch vụ cao nhất lại có quy mô nhỏ nhất và ngược lại.

4.6. Tương quan và Feature Superiority Ranking



- Pearson/Spearman: loại `TotalCharges` ($r = 0,77$ với `tenure`); thay `tenure / MonthlyCharges` bằng `loyalty_tier / charge_segment`.
- Cramer's V: giữ `composite_risk_profile`, `security_score`, `manual_payment`, `demographic_profile`.

Hạng	Feature	Hệ số
1	Siêu cờ Tổ hợp rủi ro	0,54
2	Log Áp lực chi phí	0,53
3	Điểm Khiên Bảo vệ	0,49
4	Mức độ gắn bó	0,43
5	Phân khúc Vòng đời	0,33
6	Phân khúc Cước phí	0,31

Kết luận: Engineered Features áp đảo Original Features.

4.7. Thanh lọc và Model Schema

Nguyên tắc **Winner-takes-all** + **Noise Removal** — loại **11** biến (`TotalCharges` , `zero_supportive_service` , `tenure` , `MonthlyCharges` , nhân khẩu học gốc, `gender` , `bill_shock_ratio` , `id` , `Churn` text).

Kết quả: 34 → **23** features (22 input + `churn_flag`). Sẵn sàng chuyển giao **Modeling Pipeline** (mục 5).

5. Xây dựng Pipeline Machine Learning

5.1. Kiến trúc tổng thể

Dự án triển khai pipeline MLOps gồm **6 giai đoạn**, điều phối bởi `main.py` . Mỗi stage là module độc lập — chạy riêng để debug hoặc chạy liên tiếp qua `python main.py` .

Stage	Tên	Input	Output chính
01	Data Ingestion	<code>data/*.zip</code>	<code>train.csv</code> , <code>test.csv</code>
02	Data Validation	CSV + <code>schema.yaml</code>	<code>status.txt</code> (True/False)
03	Data Transformation	CSV thô	<code>.npz</code> đã transform, <code>preprocessor.joblib</code>
04	Model Training	<code>.npz</code>	<code>model.joblib</code> , <code>metrics.json</code>
05	Model Evaluation	Model + test data	Predictions, biểu đồ, MLflow logs
06	Prediction	Model + test CSV	<code>submission.csv</code>

Lưu đồ dữ liệu: Zip → CSV → Validate → Feature Engineering + SMOTE → Train/Compare → Evaluate → Predict → Submit.

Ưu điểm của MLflow so với notebook thông thường

So với việc phát triển và thử nghiệm mô hình thủ công trong Jupyter Notebook, kiến trúc MLOps tích hợp MLflow mang lại các ưu điểm vượt trội: - **Theo dõi thí nghiệm tự động (Experiment Tracking):** Ghi nhận có hệ thống toàn bộ siêu tham số (parameters), các chỉ số đánh giá (Accuracy, Precision, Recall, F1, ROC AUC) và các file đồ thị (Confusion Matrix, ROC Curve) qua mỗi lượt chạy (run). Không còn tình trạng ghi đè hoặc quên ghi chép kết quả như trên notebook. - **Khả năng tái lập và tự động hóa (Reproducibility):** Quy trình được module hóa thành các file script chạy độc lập. Khi cấu hình thay đổi (qua file YAML), pipeline tự động chạy lại từ đầu đến cuối mà không lo ngại lỗi do chạy các ô code sai thứ tự như trong môi trường notebook. - **Quản lý mô hình tập trung (Model Registry & Artifacts):** Đóng gói và lưu trữ `preprocessor.joblib` cùng file mô hình học máy

(`model.joblib`), kèm theo metadata và requirements một cách hệ thống, sẵn sàng phục vụ triển khai (deploy) thay vì để các file mô hình phân tán trong thư mục.

5.2. Chi tiết từng giai đoạn

Stage 01 — Data Ingestion

Giải nén `playground-series-s6e3.zip` → `artifacts/data_ingestion/train.csv` (594.194 dòng) và `test.csv` (254.655 dòng).

Stage 02 — Data Validation

So khớp cột và kiểu dữ liệu với `config/schema.yaml`. Schema sai → pipeline dừng sớm, tránh train trên dữ liệu lỗi cấu trúc.

Stage 03 — Data Transformation

Nhóm cột	Xử lý
Numeric (5 feature phái sinh)	Imputer (median) → Winsorizer (P1–P99) → StandardScaler
Categorical (10 biến gốc)	Imputer (mode) → OneHotEncoder (drop='first')
Binary (PhoneService, PaperlessBilling)	Imputer → OneHotEncoder
Ordinal (loyalty_tier, charge_segment, demographic_profile)	Imputer
Engineered binary (manual_payment, composite_risk_profile)	Imputer

Chống leakage: Pipeline **chỉ fit trên train**, transform test bằng cùng tham số đã học.

SMOTE: Chỉ trên train sau transform → **920.754** mẫu (50:50). Test **không** oversample.

Stage 04 — Model Training

Mô hình	Tham số tìm kiếm (Grid Search)	Siêu tham số tối ưu (Best Params)	CV ROC AUC
LightGBM	<code>n_estimators : [100, 200]</code> <code>max_depth : [3, 5, 7]</code> <code>learning_rate : [0.1]</code>	<code>n_estimators : 200</code> <code>max_depth : 7</code> <code>learning_rate : 0.1</code>	0.9311
XGBoost	<code>n_estimators : [100, 200]</code> <code>max_depth : [3, 5, 6]</code>	<code>n_estimators : 200</code> <code>max_depth : 6</code>	0.9310

Mô hình	Tham số tìm kiếm (Grid Search)	Siêu tham số tối ưu (Best Params)	CV ROC AUC
	learning_rate : [0.1]	learning_rate : 0.1	

Chia tập dữ liệu theo tỷ lệ 80/20 stratified, áp dụng Cross-Validation 3-fold trên tập huấn luyện, lựa chọn mô hình dựa trên scoring ROC AUC , tích hợp logging tự động qua MLflow và lưu trữ mô hình tối ưu nhất dưới định dạng joblib .

Stage 05 — Model Evaluation

Dự đoán validation, tính toán các metrics (Accuracy, Precision, Recall, F1, ROC AUC), tự động xuất Confusion Matrix và ROC Curve lưu trực tiếp vào thư mục docs/ .

Stage 06 — Prediction

Load mô hình tối ưu nhất (model.joblib) cùng preprocessor (preprocessor.joblib) → chuyển đổi dữ liệu kiểm thử Kaggle → xuất file kết quả cuối cùng submission.csv chứa cột id và nhãn Churn .

5.3. Tổng hợp các đặc trưng đã được tạo

Dưới đây là tổng hợp các đặc trưng phái sinh chính được tạo ra trong quy trình Feature Engineering nhằm nâng cao hiệu suất phân loại của mô hình:

Tên đặc trưng	Loại dữ liệu	Công thức / Quy tắc tạo	Ý nghĩa nghiệp vụ
loyalty_tier	Ordinal	Phân khoảng tenure thành 5 nhóm: Onboarding (0-6 tháng), First Year (6-12), Second Year (12-24), Familiar (24-48), Loyal (>48).	Phân nhóm mức độ gắn bó của khách hàng thay vì dùng biến liên tục.
charge_segment	Ordinal	Phân khoảng MonthlyCharges thành 3 nhóm: Budget (0-35\$), Standard (35-70\$), Premium (>70\$).	Phân khúc chi phí hàng tháng.
charge_to_tenure_ratio_log	Numeric	$\log1p(\text{MonthlyCharges} / \text{tenure})$	Đo lường áp lực chi phí tích lũy tương đối theo thời gian sử dụng dịch vụ.

Tên đặc trưng	Loại dữ liệu	Công thức / Quy tắc tạo	Ý nghĩa nghiệp vụ
average_cost_per_service	Numeric	$\text{MonthlyCharges} / \text{total_active_services}$	Mức chi phí trung bình mà khách hàng phải chi trả trên mỗi dịch vụ đăng ký.
security_score	Numeric	Tổng số dịch vụ bảo vệ đã đăng ký (tối đa 4 dịch vụ: OnlineSecurity, TechSupport, OnlineBackup, DeviceProtection). Trả về -1 nếu không dùng Internet.	Sức giữ chân của hệ sinh thái bảo mật.
streaming_score	Numeric	Tổng số dịch vụ streaming đã đăng ký (tối đa 2: StreamingTV, StreamingMovies). Trả về -1 nếu không dùng Internet.	Mức độ gắn kết với dịch vụ giải trí.
manual_payment	Binary	1 nếu phương thức thanh toán là Electronic/Mailed Check; 0 nếu tự động (Bank transfer, Credit card).	Xác định các phương thức thanh toán thủ công có rủi ro rời bỏ cao.
composite_risk_profile	Binary	1 nếu khách hàng có hợp đồng Month-to-month và sử dụng Internet cáp quang Fiber Optic; 0 cho các trường hợp khác.	Siêu cờ nhận diện phân khúc khách hàng mang rủi ro rời bỏ cao nhất.
demographic_profile	Ordinal	Phân lớp nhân khẩu học kết hợp từ SeniorCitizen, Partner, Dependents (như Nuclear Family, Isolated Senior, v.v.).	Phân nhóm đối tượng dựa trên bối cảnh cá nhân và ràng buộc gia đình.

6. Kết quả mô hình

6.1. So sánh mô hình

Dưới đây là bảng so sánh hiệu năng chi tiết giữa hai mô hình **LightGBM** và **XGBoost** sau khi tối ưu hóa bằng GridSearchCV trên tập validation:

Mô hình	ROC AUC	F1-Score	Accuracy	Precision	Recall	Kết quả
LightGBM	93.39%	87.26%	86.66%	83.52%	91.34%	✅ Tốt nhất (Selected)
XGBoost	93.01%	86.63%	86.03%	83.04%	90.55%	—


Nhận xét: Cả hai mô hình đều đạt hiệu năng vượt trội nhờ hệ thống đặc trưng phái sinh chất lượng từ quy trình Feature Engineering. Tuy nhiên, **LightGBM** cho kết quả tối ưu hơn trên tất cả các khía cạnh đo lường, đặc biệt là chỉ số **Recall (91.34%)** và **ROC AUC (93.39%)**. Do đó, LightGBM được lựa chọn làm mô hình dự đoán chính thức cho dự án.

6.2. Metrics chi tiết (Validation Set — LightGBM)

Metric	Giá trị	Diễn giải trong bài toán Churn
Accuracy	86.66%	Tổng thể dự đoán đúng, đạt mức cao đối với bài toán mất cân bằng dữ liệu
Precision	83.52%	83.52% cảnh báo rời bỏ dịch vụ của mô hình là chính xác, giúp tối ưu chi phí retention
Recall	91.34%	Mô hình phát hiện được hơn 91.34% lượng khách hàng thực sự có nguy cơ rời bỏ
F1-Score	87.26%	Đạt độ cân bằng tối ưu giữa Precision và Recall trên tập dữ liệu mất cân bằng
ROC AUC	93.39%	Khả năng phân tách và xếp hạng mức độ rủi ro cực kỳ tốt của mô hình

Tại sao ưu tiên Recall? Trong bài toán dự đoán rời bỏ dịch vụ viễn thông, **bỏ sót một khách hàng rời đi (False Negative)** thường mang lại tổn thất chi phí cao hơn nhiều so với **cảnh báo nhầm một khách hàng trung thành (False Positive)**. Khi Recall đạt 91.34%, doanh nghiệp sẽ chủ động tiếp cận sớm phần lớn tập khách hàng có nguy cơ rời dịch vụ.

6.3. Ma trận nhầm lẫn (Confusion Matrix)




Phân tích Confusion Matrix (184.151 mẫu validation):

	Dự đoán: No (0)	Dự đoán: Yes (1)
Thực tế: No (0)	75.489 (TN)	16.587 (FP)
Thực tế: Yes (1)	7.969 (FN)	84.106 (TP)

Chỉ số	Giá trị	Ý nghĩa
Recall (Churn)	91.34%	Phát hiện thành công 91.34% khách hàng thực sự rời đi (84.106 trên tổng số 92.075)
Precision (Churn)	83.52%	Trong số khách hàng mô hình dự báo rời đi, có 83.52% là chính xác
Specificity	81.99%	Nhận diện đúng 81.99% nhóm khách hàng tiếp tục gắn bó (75.489 trên tổng số 92.076)
False Negative Rate	8.66%	Tỷ lệ bỏ sót khách hàng rời đi chỉ ở mức 8.66%

Độc ma trận dưới góc độ kinh doanh: Việc phát sinh 16.587 trường hợp cảnh báo nhầm (False Positive) tương đương với việc doanh nghiệp sẽ tốn thêm một phần chi phí chăm sóc khách hàng/gửi chương trình khuyến mãi cho tập khách hàng này. Tuy nhiên, đây là khoản "phí bảo hiểm" hoàn toàn chấp nhận được để tránh bỏ sót 7.969 khách hàng rời đi thực sự (đã được mô hình thu hẹp tối đa thông qua chỉ số Recall vượt trội).

6.4. Đường cong ROC (ROC Curve)



- **AUC = 0.9339** — mô hình có khả năng phân tách rủi ro rất tốt.
- Đường cong ROC nằm sát góc trên-trái, vượt xa đường Random Classifier (AUC = 0.5).

6.5. Artifacts được tạo ra

Quy trình chạy tự động (Pipeline) sinh ra các tệp tin trung gian và kết quả đầu ra (Artifacts) được tổ chức khoa học nhằm phục vụ kiểm tra và tái lập kết quả:

Thư mục / File	Thành phần	Mô tả chi tiết vai trò
<code>artifacts/data_ingestion/</code>	<code>train.csv</code> (594.194 mẫu) <code>test.csv</code> (254.655 mẫu)	Dữ liệu thô (Raw Data) sau khi được giải nén tự động từ tệp zip đầu vào, sẵn sàng cho khâu kiểm định chất lượng.
<code>artifacts/data_validation/</code>	<code>status.txt</code> (chứa giá trị True / False)	Ghi nhận trạng thái kiểm định dữ liệu. Giá trị True xác nhận dữ liệu khớp hoàn toàn cấu trúc schema, cho phép pipeline tiếp tục vận hành.
<code>artifacts/data_transformation/</code>	<code>train_transformed.npz</code> <code>test_transformed.npz</code> <code>preprocessor.joblib</code>	- <code>preprocessor.joblib</code> : Pipeline tiền xử lý đã huấn luyện (chứa các tham số Imputer, Scaler, One-Hot Encoder). - File <code>.npz</code> : Dữ liệu dạng ma trận nén chứa các đặc trưng phái sinh đã được chuẩn hóa và áp dụng kỹ thuật cân bằng lớp SMOTE (trên tập train), sẵn sàng để nạp trực tiếp vào mô hình.
<code>artifacts/model_trainer/</code>	<code>model.joblib</code> <code>metrics.json</code>	- <code>model.joblib</code> : Tệp lưu trữ mô hình tốt nhất (LightGBM) sau khi hoàn tất GridSearchCV. - <code>metrics.json</code> : Lưu trữ các chỉ số đánh giá chi tiết của mô hình được chọn trên tập Validation để MLflow/API truy xuất nhanh.
<code>artifacts/model_evaluation/</code>	<code>predictions.npz</code>	Lưu trữ xác suất dự báo chi tiết và nhãn dự đoán tương ứng trên tập validation để phục vụ vẽ biểu đồ và phân tích sâu hành vi dự báo.
<code>submission.csv</code> (thư mục gốc)	Tệp kết quả dự đoán Kaggle	Tệp tin đầu ra cuối cùng chứa cột <code>id</code> và dự báo <code>Churn</code> (Yes/No) của tập kiểm thử Kaggle, định dạng chuẩn để nộp bài.
<code>mlruns/</code>	Cơ sở dữ liệu thí nghiệm MLflow	Thư mục cục bộ lưu trữ lịch sử cấu hình, thông số

Thư mục / File	Thành phần	Mô tả chi tiết vai trò
		hyperparameter của tất cả các run đã thực hiện, hỗ trợ giao diện UI trực quan hóa so sánh.

7. Kết luận và hướng phát triển

7.1. Kết luận

Dự án **Customer Churn Prediction** đã hoàn thành đầy đủ quy trình từ phân tích dữ liệu đến triển khai mô hình:

- EDA chuyên sâu** đã xác định rõ các yếu tố rủi ro: hợp đồng ngắn hạn, Fiber optic, thiếu dịch vụ bảo mật, thanh toán thủ công và phân khúc nhân khẩu học.
- Feature Engineering** tạo ra 10 đặc trưng phái sinh có mật độ thông tin cao, đặc biệt `composite_risk_profile` (55% churn) và `demographic_profile` (Risk Spread 49.7%).
- Pipeline MLOps** 6 giai đoạn tự động hóa toàn bộ quy trình, tích hợp MLflow tracking và có thể chạy từng stage độc lập.
- Mô hình LightGBM** đạt **ROC AUC 93.39%** với Recall **91.34%** và F1-Score **87.26%** trên nhóm churn — tối ưu vượt trội cho bài toán phát hiện sớm khách hàng có nguy cơ rời bỏ.

7.2. Ý nghĩa thực tiễn

Dựa trên EDA và kết quả mô hình, doanh nghiệp có thể ưu tiên can thiệp theo thứ tự:

Ưu tiên	Phân khúc	Hành động đề xuất
1	<code>composite_risk_profile = 1</code> (Fiber + Month-to-month)	Ưu đãi chuyển hợp đồng dài hạn, giảm cước gói bảo mật
2	<code>manual_payment = 1</code>	Khuyến khích chuyển sang auto-pay (credit card, bank transfer)
3	<code>security_score</code> thấp	Cross-sell OnlineSecurity, TechSupport
4	<code>demographic_profile = 2</code> (Isolated Senior)	Hỗ trợ kỹ thuật chủ động, hotline ưu tiên
5	<code>loyalty_tier</code> 0-1 + <code>change_segment</code> Premium	Giảm "bill shock" cho khách mới cước cao

7.3. Hạn chế

- Dữ liệu là bộ synthetic từ Kaggle Playground, có thể khác phân phối so với dữ liệu thực tế.
- Chưa triển khai giải thích mô hình (SHAP/LIME) để hiểu từng dự đoán cụ thể.
- Chưa đánh giá trên tập test có nhãn (Kaggle chỉ chấm điểm qua leaderboard).

7.4. Hướng phát triển

- Tích hợp **SHAP values** để giải thích feature importance từng dự đoán.
- Mở rộng sang **web application** (frontend + backend API) cho phép nhập thông tin khách hàng và nhận dự đoán real-time.
- Thử nghiệm thêm mô hình **CatBoost, Stacking Ensemble**.
- Triển khai **model monitoring** để phát hiện data drift trên production.